

Implementación y Análisis de Recocido Simulado por Aceptación de Umbrales para el Problema del Agente Viajero

Wendy Sánchez Cortés^{*,a}

^aFacultad de Ciencias, Universidad Nacional Autónoma de México

Seminario de Heurísticas de Optimización Combinatoria. Proyecto 1. Fecha de entrega: September 16, 2026

Abstract

Este documento presenta la implementación y aplicación del algoritmo de Recocido Simulado por Aceptación por Umbrales para abordar el Problema del Agente Viajero (TSP) en su variante de camino hamiltoniano. La experimentación se centra en evaluar el rendimiento y la convergencia de la heurística para resolver dos instancias particulares de 40 y 150 ciudades.

1. INTRODUCCIÓN

El Problema del Agente Viajero, también llamado TSP por sus siglas en inglés, es uno de los desafíos clásicos más estudiados en la optimización combinatoria. Dada una lista de ciudades y las distancias entre ellas, consiste en encontrar la ruta de menor costo que pase por cada una de ellas exactamente una vez y regrese al punto de partida. [1] En términos formales, esto equivale a encontrar el ciclo hamiltoniano de menor peso en una gráfica. Para ello, en primera instancia, podríamos evaluar todas las permutaciones posibles mediante fuerza bruta y tomar la mejor. Teóricamente esto es posible, en la práctica inviable; la complejidad de este enfoque crece en un orden de $\mathcal{O}(N!)$, lo que lo vuelve intratable incluso para conjuntos pequeños de ciudades. Es por ello que este problema se cataloga como NP-Hard, ya que no existe un algoritmo conocido capaz de garantizar una solución óptima en tiempo polinomial.

No obstante, el TSP no es una abstracción solamente teórica. Como su propio nombre lo indica, inspirado en un vendedor que va de ciudad en ciudad, es un problema humano y cotidiano; lo encontramos en la planeación de rutas de transporte público, en la logística de paquetería e incluso en el análisis de la secuenciación del ADN. La complejidad computacional nos marca limitaciones, por el tiempo no se nos permite encontrar la ruta perfecta, pero podemos aspirar a encontrar una suficientemente buena. Ahí es donde entran las heurísticas. Métodos como el Recocido Simulado, originalmente *Simulated Annealing*, nos permiten explorar de manera estocástica e inteligente el espacio de búsqueda y llegar a soluciones que si bien no son perfectas, son competitivas para resolver los problemas de los humanos de carne y hueso.

Como parte del primer proyecto del Seminario de Heurísticas de Optimización Combinatoria, se implementó Aceptación por Umbrales, *Threshold Accepting* en inglés, una simplificación determinista del Recocido Simulado introducida por Dueck y Scheuer. Específicamente, buscamos resolver la variante de TSP del camino hamiltoniano, la cual conserva intacta su complejidad NP-Hard. Este documento detalla el diseño del sistema y el proceso de experimentación para encontrar soluciones a dos instancias particulares de 40 y 150 ciudades. Si bien la experimentación y afinación de los hiperparámetros están centradas en esta meta específica, el sistema se construyó alrededor de una interfaz *Solution*, la cual desacopla la lógica del recocido del TSP, dando como resultado un marco de trabajo extensible. De este modo, el TSP resulta intercambiable por otros problemas que también se pueden resolver bajo este enfoque, tales como el problema de las N-Reinas, el Sudoku, Vehicle Routing Problem, entre otros. La implementación del programa se encuentra en C++, hace uso del paralelismo mediante múltiples hilos de ejecución para acelerar los experimentos, integra SQLite y genera reportes en formato CSV para su análisis posterior.

2. BACKGROUND: RECOCIDO SIMULADO

El Recocido Simulado fue propuesto por Kirkpatrick, Gelatt y Vecchi en 1983 como una técnica de optimización inspirada en el proceso metalúrgico de recocido, en el que un metal se calienta y luego se enfría lentamente [1]. La idea central es trasladar el algoritmo de Metropolis, usado en mecánica estadística para simular un sistema de átomos en equilibrio térmico a una temperatura dada, al contexto de optimización, sustituyendo la energía del sistema por una función de costo y la temperatura por un parámetro de control T . En cada paso, se propone una configuración vecina y si esta reduce el costo, se acepta. Por otro lado, si lo incrementa en ΔE , se acepta con cierta probabilidad $\exp(-\Delta E/k_B T)$. Al repetir este procedimiento mientras T disminuye gradualmente, el sistema puede escapar de mínimos locales en las etapas iniciales para después refinar la solución hacia el final. Esto lo diferencia del enfoque greedy, que sólo acepta movimientos que mejoran el costo y por ello queda atrapada fácilmente en óptimos locales [3].

Más tarde Dueck y Scheuer propusieron Aceptación por Umbrales, una variante determinista de esta idea. Esta es la que se implementó en este proyecto. En lugar de aceptar movimientos que empeoran el costo con una probabilidad dependiente de T , se acepta cualquier vecino s' de la solución actual s tal que $f(s') \leq f(s) + T$. El algoritmo organiza las iteraciones en *lotes* de tamaño L que terminan cuando se han aceptado L soluciones vecinas. La temperatura se mantiene fija mientras el promedio de costo aceptado por lote siga mejorando, pero en cuanto dos lotes consecutivos no mejoran, la temperatura se multiplica por un factor de enfriamiento $\varphi \in (0, 1)$. El proceso completo termina cuando T cae por debajo de un umbral ϵ [2].

3. DISEÑO DEL SISTEMA

Para abordar el problema es necesario precisar ciertas definiciones, estas se encuentran con mayor detalle en las especificaciones dadas en el curso. A continuación se presenta un resumen.

3.1. Representación del problema

Dado un subconjunto S de ciudades, la gráfica de conexiones reales entre ellas en general no es completa. Por ello, para poder considerar cualquier permutación de S como una solución válida, es necesario construir la gráfica completa G_S , pero con una función de peso aumentada $w_S : E_S \rightarrow \mathbb{R}^+$ definida como:

$$w_S(u, v) = \begin{cases} w(u, v) & \text{si } (u, v) \in E \\ d(u, v) \times \max_d(S) & \text{en otro caso} \end{cases}$$

donde $d(u, v)$ es la distancia natural entre u y v (que se obtiene con la fórmula de Haversine con el supuesto de que la Tierra es una esfera perfecta) y $\max_d(S)$ es la distancia real máxima en S . Esta penalización evita que en la solución final haya aristas que no existen en la gráfica original.

El costo de una solución se normaliza dividiendo la suma de las distancias del recorrido entre la suma de las $|S| - 1$ aristas reales más pesadas de S , $\mathcal{N}(S)$. De esta forma, toda solución factible es aquella que sólo usa aristas reales y por ende, siempre se evalúa en el intervalo $[0, 1]$ [4]. Y así la función de costo $f(P)$ para $P = v_{\rho(1)}, \dots, v_{\rho(k)}$ está dada por la suma de sus aristas entre elementos consecutivos dividida por el normalizador [4]:

$$f(P) = \frac{\sum_{i=2}^k w_S(v_{\rho(i-1)}, v_{\rho(i)})}{\mathcal{N}(S)}$$

En el modelo inicial, la vecindad se construye a partir de hacer el intercambio de dos posiciones en el tour actual [4]. Por eficiencia, el costo de cada propuesta se calcula de forma parcial, revisando únicamente las aristas que son afectadas por el intercambio, en lugar de recalcularlo completo de la solución.

3.2. Arquitectura del sistema

El sistema fue diseñado bajo un enfoque modular y orientado a objetos en C++. Hay responsabilidades claramente separadas como el acceso a datos, la representación del problema, la heurística de optimización y la gestión de experimentos. Esta división se ve reflejada en la organización del código fuente:

```
core/          # Lógica central (EnvironmentTSP, SolutionTSP)
db/            # DAO con SQLite (CityDatabase)
experiment/    # Experimentación (RunConfig, RunResult, Runner)
heuristic/     # Algoritmos (SimulatedAnnealing, InitialTemp)
io/            # Entrada y salida
model/         # Estructuras de datos (City, Connection)
```

Para la lectura de los datos, se implementó un DAO a través de la clase `CityDatabase`. Esta clase interactúa directamente con una base de datos en SQLite cuyo esquema particular es:

```
CREATE TABLE cities (
  id INTEGER PRIMARY KEY, name TEXT, country TEXT,
  population INTEGER, latitude DOUBLE, longitude DOUBLE
);
CREATE TABLE connections (
  id_city_1 INTEGER, id_city_2 INTEGER, distance DOUBLE,
  PRIMARY KEY (id_city_1, id_city_2),
  FOREIGN KEY (id_city_1) REFERENCES cities(id),
  FOREIGN KEY (id_city_2) REFERENCES cities(id)
);
```

Code 1. Esquema relacional de la base de datos.

Los registros recuperados por el DAO se mapean a las estructuras `City` y `Connection`, para que posteriormente, con dicha información, se inicialice `EnvironmentTSP`. Esta clase crea el contexto del problema: se encarga de construir la gráfica completa tal como fue definida previamente, de encontrar la arista de mayor distancia y calcular el normalizador $\mathcal{N}(S)$.

El sistema separa explícitamente la representación del problema del algoritmo de búsqueda, a través de la interfaz abstracta `Solution` con los métodos `proposeNeighborCost`, `acceptPropose`, `evaluate`, `saveBest` y `restoreBest`. Tanto el cálculo de la temperatura inicial como el ciclo principal de Aceptación por Umbrales están escritos en términos de esta interfaz, sin referencia a ciudades, coordenadas o distancias. La clase `SolutionTSP` es quien conoce los detalles del TSP como la matriz de distancias aumentadas, el camino actual, el cálculo del costo de un intercambio, etc.

```
class Solution {
protected:
    double cost;

public:
    virtual double proposeNeighborCost() = 0;
    virtual void acceptPropose() = 0;

    virtual double evaluate() = 0;
    virtual void saveBest() = 0;
    virtual void restoreBest() = 0;

    virtual std::string toString() = 0;

    double getCost(){
        return cost;
    }
};
```

Code 2. Definición de la interfaz `Solution`.

La heurística está implementada en `SimulatedAnnealing`, una clase que maneja los ciclos de lotes y el enfriamiento. Por otro lado, la clase `InitialTemperature` implementa al pie de la letra el algoritmo de búsqueda binaria visto en el curso.

Finalmente, se diseñó un módulo dedicado a la gestión de la experimentación. Para ello, se abstraieron las variables de entrada y los resultados en dos estructuras: `RunConfig` y `RunResult`:

```
struct RunConfig {
    std::string label = "";
    int seed;
    double targetP, epsilonP, initialT;
    int tempSample, batch, maxAttempts;
    double coolingFactor, epsilon;
};

struct RunResult {
    RunConfig config;
    std::vector<int> finalPath;
    std::string timestamp;
    double initialCost = 0.0, initialTemperature = 0.0;
    double finalCost = 0.0;
    long long elapsedMs = 0;
};
```

Code 3. Estructuras para la gestión de experimentos.

La clase `ExperimentRunner` toma múltiples objetos `RunConfig` para correr de forma concurrente diferentes ejecuciones. Una vez que los hilos concluyen su trabajo, se recolecta un arreglo de objetos `RunResult` que son procesados por `ExperimentReporter` para generar un archivo CSV reportando los resultados.

4. EXPERIMENTACIÓN Y RESULTADOS

La fase de experimentación se llevó a cabo a la par del desarrollo del sistema, por lo que hubo cambios importantes que marcaron 3 etapas. Cabe resaltar que esta fase se centró en dar solución a la instancia del problema de 150 ciudades, por tener una mayor dificultad. Todos los reportes generados se encuentran en el anexo A.

TSP de 150

Las instancias del problema de interés están dadas por los identificadores de las ciudades, cuyas coordenadas y conexiones se encuentran definidas en la base de datos del anexo B. Por el componente estocástico del sistema, para la reproducibilidad de los experimentos es necesario proporcionarle al programa las mismas entradas sin alterar el orden. A continuación la entrada constante que se utilizó durante esta etapa:

Input

Instancia de 150 ciudades: 1, 2, 3, 4, 5, 6, 7, 8, 9, 11, 12, 14, 16, 17, 19, 20, 22, 23, 25, 26, 27, 74, 75, 77, 163, 164, 165, 166, 167, 168, 169, 171, 172, 173, 174, 176, 179, 181, 182, 183, 184, 185, 186, 187, 244, 297, 326, 327, 328, 329, 330, 331, 332, 333, 334, 336, 339, 340, 343, 344, 345, 346, 347, 349, 350, 351, 352, 353, 444, 483, 489, 490, 491, 492, 493, 494, 495, 496, 499, 500, 501, 502, 504, 505, 507, 508, 509, 510, 511, 512, 520, 652, 653, 654, 655, 656, 657, 658, 660, 661, 662, 663, 665, 666, 667, 668, 670, 671, 673, 674, 675, 676, 678, 815, 816, 817, 818, 819, 820, 821, 822, 823, 825, 826, 828, 829, 832, 837, 839, 840, 978, 979, 980, 981, 982, 984, 985, 986, 988, 990, 991, 995, 999, 1001, 1003, 1004, 1037, 1038, 1073, 1075




Figure 1. 150 ciudades en el mapa

Etapas

Etapas
En la primera etapa no se tenía el módulo automatizado para las pruebas, por lo que la afinación de los hiperparámetros se realizó de forma manual y empírica. Durante esta fase temprana se ejecutaron las primeras 15,000 iteraciones manteniendo los parámetros constantes y variando únicamente la semilla. El índice de soluciones factibles rondaba en el 7% y la mejor solución encontrada evaluaba a 0.15001.

Etapas

Posteriormente, en la segunda etapa, se concluyó la implementación del módulo de experimentación. Esto marcó un punto de inflexión en el proyecto, ya que permitió automatizar y escalar significativamente el volumen de pruebas concurrentes, además de brindar un mayor control y registro sistemático de los resultados.

Tras evaluar 60,000 semillas con variaciones ligeras en los hiperparámetros, se alcanzó una solución con una función de costo de 0.143194 con la siguiente configuración de parámetros:

```
-seed 3259
-targetP 0.9
-epsilonP 0.00001
-initialT 8
-tempSample 5000
-coolingFactor 0.95
-epsilon 0.00001
-batchSize 5000
-maxAttempts 150
```

Con estos argumentos, se obtuvo la siguiente ruta:




Figure 2. Ruta de costo 0.143194 para tsp 150.

La secuencia ordenada de la solución se detalla a continuación:

171, 77, 183, 346, 75, 821, 512, 483, 1075, 652, 179, 671, 16, 520, 186, 675, 340, 502, 828, 12, 1038, 339, 244, 826, 444, 17, 164, 11, 984, 995, 837, 979, 493, 509, 329, 19, 839, 496, 182, 673, 665, 344, 653, 490, 654, 26, 820, 345, 332, 181, 14, 982, 187, 816, 678, 823, 7, 507, 656, 667, 184, 815, 9, 832, 661, 663, 657, 829, 1, 986, 508, 168, 505, 2, 173, 172, 163, 676, 22, 185, 351, 991, 27, 353, 990, 333, 3, 165, 981, 1004, 6, 5, 978, 352, 668, 176, 23, 988, 174, 4, 489, 817, 347, 499, 491, 492, 25, 501, 1003, 349, 331, 662, 8, 999, 334, 674, 985, 343, 510, 660, 20, 825, 500, 504, 511, 327, 670, 350, 840, 336, 980, 297, 1001, 74, 822, 166, 658, 666, 818, 655, 819, 330, 1073, 169, 1037, 326, 328, 167, 495, 494

Este proceso involucró la evaluación de más de 3 millones de soluciones potenciales. La siguiente gráfica corresponde a la temperatura de aceptación a lo largo de la ejecución:




Figure 3. Evolución de la función de costo con respecto a la aceptación.

No obstante, de las 60,000 semillas evaluadas, la mejor solución se obtuvo con el número 3259, mientras que las 56,741 restantes no lograron superar dicho resultado. Aunque este desarrollo se realizó

de manera individual, influyó fuertemente la comparación con los resultados de otras personas que abordaban a la par el mismo problema.

Etapas 3

Lo que marcó la transición de la segunda a la tercera etapa de experimentación fue la modificación del modelo, particularmente la generación de la vecindad. Inicialmente el sistema implementó de forma estricta la definición planteada en la asignatura, generando vecinos mediante el intercambio de dos ciudades elegidas al azar. Con este modelo, el sistema tendía a estancarse en valores 0.14 para la instancia de 150 ciudades. Al realizar un análisis comparativo entre la mejor solución obtenida por este proyecto (0.1431) y los resultados del resto del grupo hasta ese momento (0.140), se observó que el intercambio necesario para igualar las soluciones necesitaba invertir simplemente el orden de un segmento completo. Bajo el esquema que se tenía, resultaba muy poco probable, ya que cada cambio destruye hasta cuatro aristas dentro de la gráfica, lo que rompe la estructura global del recorrido y reduce la probabilidad de conservar aristas óptimas. Para mitigar este problema, se sustituyó el operador por inversión de subarreglos, *2-opt*, similar a la propuesta original de Kirkpatrick.

Con este nuevo enfoque, al seleccionar dos índices aleatorios i y j , en lugar de intercambiar únicamente las ciudades en esas posiciones, se invierte el segmento intermedio que las conecta. Esto solo altera a lo más dos aristas del recorrido total. La implementación fue notable, permitió al algoritmo descender a valores inferiores a 0.14.

Además de este cambio, en la tercera etapa se implementó una generación aleatoria para los hiperparámetros dentro de rangos acotados. Tras varias pruebas, se determinó empíricamente que no resultaba conveniente variar la condición de paro del algoritmo (ϵ) ni los parámetros de la heurística de temperatura inicial. Así que estos valores se mantuvieron constantes: $\epsilon = 0.00001$, $\epsilon_p = 0.00001$ y una temperatura inicial de $T_0 = 8$.

Los hiperparámetros que sí variaron se obtuvieron a partir de distribuciones uniformes aleatorias:

- Probabilidad objetivo (targetP): entre 0.7000 y 0.9500.
- Factor de enfriamiento (coolingFactor): entre 0.8500 y 0.9800.
- Tamaño del lote (batchSize): entre 1000 y 5000.
- Muestra de temperatura (tempSample): entre 1000 y 5000.
- Intentos máximos (maxAttempts): entre 50 y 200.

Con esto, el sistema logró generar un 100% de soluciones factibles y alcanzar un costo de 0.13624, el cual representa el mejor resultado registrado en todo el proyecto. Esta solución no se obtuvo de manera aislada, sino que fue recurrente entre el 3% y el 15% de las ejecuciones.

En la Tabla 1 se presentan 17 semillas distintas que lograron converger exactamente a la misma solución con el costo mínimo de 0.13624. Algunas ejecuciones arrojaron la misma ruta pero en orden inverso.

El mapa de la solución y la secuencia de los identificadores de la respuesta de costo 0.13624 es la siguiente:

171, 652, 1075, 483, 512, 821, 75, 346, 77, 183, 179, 671, 16, 520, 186, 675, 340, 502, 828, 12, 1038, 339, 244, 826, 444, 17, 25, 492, 491, 499, 347, 817, 489, 4, 174, 165, 3, 333, 27, 353, 990, 981, 988, 23, 176, 668, 352, 978, 5, 6, 1004, 351, 991, 185, 22, 676, 665, 344, 653, 490, 654, 26, 820, 345, 332, 181, 14, 982, 187, 816, 678, 823, 7, 507, 673, 173, 2, 656, 667, 184, 815, 9, 832, 661, 663, 657, 829, 1, 986, 508, 168, 505, 19, 839, 496, 182, 172, 163, 329, 509, 493, 979, 837, 995, 984, 501, 164, 11, 1003, 349, 331, 662, 8, 999, 334, 674, 985, 343, 510, 660, 20, 825, 500, 504, 511, 327, 670, 350, 840, 336, 980, 297, 1001,



Figure 4. Ruta final obtenida por el algoritmo de Recocido Simulado para la instancia de 150 ciudades de costo 0.13624

74, 822, 166, 658, 666, 818, 655, 819, 330, 1073, 169, 1037, 326, 328, 167, 495, 494.

Si bien todos los experimentos en la Tabla 1 llegan exactamente a la misma solución, el tiempo de cómputo requerido difiere significativamente entre ellos. Por ejemplo, tomando el experimento etiquetado como exp_3_176 y exp_3_219. El primero alcanza la convergencia con aproximadamente 1 millón de evaluaciones y el segundo requiere cerca de 3 millones. Esto se ve en las Figuras 5 y 6, aun cuando la escala dificulta apreciar esta diferencia.

Parámetros del exp_3_176:

```
-seed 5026
-targetP 0.8955
-epsilonP 0.00001
-initialT 8
-tempSample 3029
-coolingFactor 0.9261
-epsilon 0.00001
-batchSize 2512
-maxAttempts 166
```




Figure 5. Evolución de la función de costo con respecto a la temperatura en la ejecución exp_3_176

Parámetros del exp_3_219:

```
-seed 5452
-targetP 0.91
-epsilonP 0.00001
-initialT 8
-tempSample 1004
-coolingFactor 0.9694
-epsilon 0.00001
```


Table 1. Parámetros y resultados ordenados por tiempo de ejecución.

label	seed	targetP	initialT	tempSample	cooling	batch	maxAtt	initialCost	finalCost	ms
exp_3_307	6331	0.7176	8	4289	0.8626	2698	71	6343092.5	0.13624	1324
exp_3_291	6176	0.8648	8	1163	0.9050	1325	127	6221527.1	0.13624	2688
exp_3_109	4356	0.8424	8	4340	0.9339	3261	86	7275850.9	0.13624	2998
exp_3_293	6192	0.7402	8	3206	0.8899	1754	161	6574041.2	0.13624	3469
exp_3_413	7392	0.7341	8	2486	0.9359	2132	84	6736284.7	0.13624	3637
exp_3_451	7778	0.9195	8	4537	0.8996	2127	136	6940206.6	0.13624	3672
exp_3_323	6492	0.8863	8	2078	0.9131	4253	98	6623070.3	0.13624	3817
exp_3_158	4842	0.8548	8	3987	0.9175	2961	109	7283770.1	0.13624	4711
exp_3_371	6978	0.9213	8	4787	0.9280	2161	165	6651777.1	0.13624	5227
exp_3_367	6929	0.7844	8	1265	0.8777	3716	192	7103496.4	0.13624	5622
exp_3_240	5664	0.7614	8	1102	0.9383	2329	119	6774678.8	0.13624	5690
exp_3_176	5026	0.8955	8	3029	0.9261	2512	166	7662501.5	0.13624	6348
exp_3_197	5229	0.7065	8	3659	0.9216	3758	158	6479806.5	0.13624	7528
exp_3_712	3971	0.9224	8	4561	0.9380	3139	133	6638076.8	0.13624	7568
exp_3_249	5756	0.9158	8	1361	0.9630	3115	194	7469804.6	0.13624	13022
exp_3_181	5076	0.8246	8	2261	0.9693	2876	164	6781088.0	0.13624	13949
exp_3_219	5452	0.9100	8	1004	0.9694	4849	172	6818784.3	0.13624	20392

-batchSize 4849
-maxAttempts 172

TSP de 40

Con estos argumentos promedio, se procedió a resolver la instancia de 40 ciudades. La entrada se presenta a continuación:

Input

Instancia de 40 ciudades: 1, 2, 3, 4, 5, 6, 7, 75, 163, 164, 165, 168, 172, 244, 327, 329, 331, 332, 333, 489, 490, 491, 492, 493, 496, 652, 653, 654, 656, 657, 815, 816, 817, 820, 978, 979, 980, 981, 982, 984




Figure 6. Evolución de la función de costo con respecto a la temperatura en la ejecución exp_3_219

Hiperparámetros promedio

A partir de un conjunto de 5,000 ejecuciones con parámetros aleatorios, se trató de calcular el promedio aritmético de las configuraciones evaluadas con el fin de definir un estándar. Los valores promedio obtenidos, tomando una entrada de n ciudades, son:

- Probabilidad objetivo (targetP): 0.8247
- Factor de enfriamiento (coolingFactor): 0.9149
- Muestra de temperatura (tempSample): $19.85 * n$
- Tamaño del lote (batch): $19.94 * n$
- Intentos máximos (maxAttempts): $0.83 * n$

Para validar estas configuraciones, empíricamente como todo en este proyecto, se diseñó un experimento de 300 ejecuciones independientes. En esta prueba, los hiperparámetros mencionados se mantuvieron fijos, junto con los parámetros definidos antes ($\epsilon = 1 \times 10^{-5}$, $\epsilon_p = 1 \times 10^{-5}$ y $T_0 = 8$), variando solo las semillas.

Como resultado, el algoritmo logró alcanzar nuevamente la mejor solución conocida de la instancia, la de 0.13624, y el 100% de las ejecuciones convergieron en rutas factibles con costos entre [0.132, 0.147].



Figure 7. 40 ciudades

Sólo fue necesario ajustar de forma proporcional aquellos hiperparámetros dependientes del tamaño de la entrada: el tamaño del lote (batch), el número máximo de intentos (maxAttempts) y la muestra de temperatura (tempSample). Tomando como referencia los promedios calculados para la instancia de 150 ciudades, la configuración escalada quedó definida así:

```
-seed 19
-targetP 0.8248
-epsilonP 0.00001
-initialT 8
-tempSample 1600
-coolingFactor 0.95
-epsilon 0.00001
-batchSize 1600
-maxAttempts 42
```

Para evaluar el desempeño en esta nueva instancia, se realizaron solo 100 ejecuciones independientes. Mantuvo el 100% de factibilidad y logró converger a la solución óptima de 0.2638195 en 25 de las 100 ejecuciones. Esta solución fue verificada con el registro histórico de cursos pasados.

La secuencia correspondiente a los identificadores de las 40 ciudades que conforman esta ruta óptima es la siguiente:

979, 493, 329, 163, 172, 496, 815, 657, 168, 1, 656, 2, 653, 490, 654, 7, 816, 982, 332, 820, 981, 333, 3, 165, 6, 5, 978, 817, 4, 489, 492, 491, 984, 331, 164, 327, 980, 244, 75, 652.




Figure 8. Ruta final obtenida por el algoritmo de Recocido Simulado para la instancia de 40 ciudades con costo 0.2638195




Figure 9. Evolución de la función de costo con respecto a la temperatura en la ejecución de costo 0.2638195

5. DIFICULTADES Y LIMITACIONES

El desarrollo e implementación de este sistema presentó diversos retos de ingeniería de software y de gestión de la experimentación. Por un lado, por una deuda técnica adquirida en las etapas tempranas del desarrollo, no se tradujeron los identificadores originales de la base de datos al momento de generar los resultados y en consecuencia, las rutas en los archivos CSV requieren un procedimiento externo para recuperar el contexto original de los datos. El mapeo es simple y puede usarse la clase `EnvironmentTSP` con las instancias de entrada para hacer la traducción.

Por otra parte, en las primeras fases del proyecto la carencia de un módulo de experimentación derivó en la pérdida de información. Al no haber parametrizado los nombres de los archivos de salida, hubo múltiples ejecuciones que sobrescribieron los reportes previos. Dolorosamente, se perdieron cerca de 20,000 ejecuciones cuyos resultados no se reportaron aquí, no fue posible recuperar los datos. También hubo inconvenientes en etapas más avanzadas de la experimentación: al generar parámetros aleatorios con una alta cantidad de decimales, el formato utilizado para guardar los registros en los archivos CSV truncaba las cifras. Esta pérdida de precisión fue catastrófica para la reproducción exacta de algunas de las mejores soluciones tempranas. Esto se resolvió limitando el número de decimales en los hiperparámetros y formateando a 10 decimales en los archivos CSV.

6. CONCLUSIONES

El sistema de Aceptación por Umbrales implementado logró resolver satisfactoriamente ambas instancias del problema. Para la instancia de 150 ciudades, el algoritmo alcanzó un costo mínimo de 0.13624, resultado reproducido de manera consistente por al menos 17 semillas distintas bajo la configuración de hiperparámetros aleatorios de la tercera etapa y con un índice de máxima factibilidad. Para la instancia de 40 ciudades, con la configuración promedio escalada al tamaño de la entrada, el sistema convergió a la solución óptima de 0.2638195 en una cuarta parte de las ejecuciones, manteniendo también la factibilidad del 100%.

Lo más relevante del proceso experimental fue el cambio del modelo de vecindad: pasar del intercambio simple de dos ciudades a la inversión de subsegmentos. Esto permitió romper el estancamiento en valores cercanos a 0.14 al preservar mejor la estructura global del recorrido en soluciones cercanas al óptimo.

Aún con estos resultados, no perfectos pero suficientemente buenos, el análisis de rendimiento reveló un patrón de estancamiento: el algoritmo alcanza la solución convergente en torno al 20% del proceso y dedica el tiempo restante a una exploración que no produce mejoras significativas. Identificar la causa exacta de este comportamiento y más importante aún, cómo mejorarlo, queda fuera del alcance de este proyecto por cuestiones de tiempo.

■ REFERENCES

- [1] S. Kirkpatrick, C. D. Gelatt, and M. P. Vecchi, "Optimization by simulated annealing", *Science*, vol. 220, no. 4598, pp. 671–680, 1983. DOI: 10.1126/science.220.4598.671
- [2] G. Dueck and T. Scheuer, "Threshold accepting: A general purpose optimization algorithm appearing superior to simulated annealing", *Journal of Computational Physics*, vol. 90, no. 1, pp. 161–175, 1990, ISSN: 0021-9991. DOI: [https://doi.org/10.1016/0021-9991\(90\)90201-B](https://doi.org/10.1016/0021-9991(90)90201-B) [Online]. Available: <https://www.sciencedirect.com/science/article/pii/002199919090201B>
- [3] D. Delahaye, S. Chaimatanan, and M. Mongeau, "Simulated annealing: From basics to applications", in *Handbook of Metaheuristics*, ser. International Series in Operations Research & Management Science, M. Gendreau and J.-Y. Potvin, Eds., vol. 272, Springer, 2019, pp. 1–35. DOI: 10.1007/978-3-319-91086-4_1
- [4] C. Peláez, *Notas del seminario de Heurísticas de Optimización Combinatoria*.